

Modelagem Espacial de Epidemias com Autômatos Celulares

Hilário Leal Cavalcanti

¹Departamento de Estatística e Informática – Universidade Federal Rural de Pernambuco (UFRPE) – Pernambuco – Brazil

hilario.cavalcanti@ufrpe.br

Resumo. Modelos compartimentais clássicos, embora úteis, desprezam a distribuição espacial e os contatos locais que são cruciais na dinâmica de epidemias. Apresento uma implementação estocástica de autômato celular para o modelo SEIR, incorporando heterogeneidade espacial e transmissão dependente da vizinhança. O código, escrito em Python com NumPy e Matplotlib, simula uma grade bidimensional com atualização síncrona e probabilidades de transição baseadas nos parâmetros epidemiológicos. Resultados mostram a formação de clusters de infecção e como intervenções localizadas (quarentena, barreiras) alteram o curso da epidemia. A ferramenta é didática e flexível, permitindo a exploração de cenários "what-if" em saúde pública. O artigo descreve a relevância do código, sua estrutura e exemplos de uso, servindo como base para estudos computacionais de doenças infecciosas.

Palavras-chave: autômatos celulares, modelo SEIR, simulação estocástica, epidemiologiaespacial, Python.

Abstract. Classical compartmental models, while useful, neglect the spatial distribution and local contacts that are crucial in the dynamics of epidemics. We present a stochastic cellular automaton implementation of the SEIR model, incorporating spatial heterogeneity and neighborhood-dependent transmission. The code, written in Python with NumPy and Matplotlib, simulates a two-dimensional grid with synchronous updating and transition probabilities based on epidemiological parameters. Results show the formation of infection clusters and how localized interventions (quarantine, barriers) alter the course of the epidemic. The tool is both didactic and flexible, allowing the exploration of "what-if" scenarios in public health. The article describes the relevance of the code, its structure, and usage examples, serving as a foundation for computational studies of infectious diseases.

Keywords: cellular automata, SEIR model, stochastic simulation, spatial epidemiology, Python.

1. Introdução

A modelagem matemática de doenças infecciosas é uma área consolidada, com contribuições seminais como o modelo SIR de Kermack e McKendrick¹. Contudo, a suposição de mistura homogênea ignora a estrutura espacial das populações, fator determinante na propagação de patógenos como o SARS-CoV-2 e o vírus da dengue^{2 3}. Modelos baseados em indivíduos (IBM) e autômatos celulares (CA) surgem como alternativas naturais para capturar interações locais e heterogeneidades^{4 5}.

O autômato celular consiste em uma grade de células, cada uma representando um indivíduo (ou um sítio), que transita entre estados epidemiológicos de acordo com regras locais e probabilidades. Essa abordagem permite visualizar a formação de clusters, efeitos de borda e o impacto de medidas de controle geograficamente direcionadas⁶.

O presente trabalho tem dois objetivos interligados: Disponibilizar um código que implementa um CA estocástico para o modelo SEIR, adequado para uso em disciplinas de modelagem e em pesquisas iniciais, além de demonstrar, por meio de exemplos concretos, como o código pode ser utilizado para investigar perguntas relevantes em epidemiologia espacial.

2. Metodologia

2.1 Modelo epidêmico

O modelo SEIR divide a população em quatro compartimentos: Suscetível (S), Exposto (E), Infectado (I) e Removido (R). A dinâmica é governada por três parâmetros: taxa de transmissão por contato (β), taxa de latência (σ , inverso do período de incubação) e taxa de recuperação (γ , inverso do período infeccioso). No contexto do autômato celular, as transições são probabilísticas e ocorrem em tempo discreto⁷.

2.2 Autômato celular espacial

A população é distribuída em uma grade $N \times N$ com condições de contorno periódicas (toróide). Cada célula está em um dos estados: 0 (S), 1 (E), 2 (I) ou 3 (R). A cada passo de tempo que será um dia, para cada célula suscetível, contam-se os vizinhos infectados na vizinhança de Moore, que seria 8 vizinhos.

A probabilidade de um suscetível se infectar é: $P(S \rightarrow E) = 1 - (1 - \beta)^{n_{\text{inf}}}$ onde n_{inf} é o número de vizinhos infectados. Um exposto torna-se infectado com probabilidade σ após o período de latência; um infectado torna-se removido com probabilidade γ . Adicionalmente, implementamos uma probabilidade de

movimento local (difusão) para simular deslocamentos diários, conforme sugerido por Keeling & Rohani⁸.

2.3 Implementação computacional

O código foi escrito em Python 3.9, usando as bibliotecas NumPy e Matplotlib, a estrutura modular inclui funções para:

- inicializar a grade com pacientes zero aleatórios;
- atualizar estados segundo as regras estocásticas;
- calcular métricas (prevalência, incidência);
- gerar gráficos de evolução temporal e snapshots espaciais.

O código evita estruturas de repetição aninhadas sempre que possível, utilizando indexação booleana do NumPy para desempenho. O tempo de execução para uma grade 100x100 e 200 passos é inferior a 2 segundos em um notebook padrão.

2.4 Experimentos de demonstração

Para ilustrar o uso, simulamos três cenários:

- A) propagação livre ($\beta=0.3$, $\sigma=0.2$, $\gamma=0.1$);
- B) intervenção com quarentena de 20% das células a partir do dia 20;
- C) barreira geográfica (bloqueio de uma linha central na grade).

Em cada caso, monitoramos o número de infectados ao longo do tempo e inspecionamos a distribuição espacial nos dias 30 e 60.

3. Resultados




Figura 1

A Figura 1 mostra as curvas epidêmicas para o cenário A. Observa-se o pico de infectados por volta do dia 60, seguido de declínio devido ao esgotamento de suscetíveis. Os snapshots espaciais revelam a formação de clusters de infecção, que coalescem à medida que a epidemia avança, um comportamento qualitativamente ausente em modelos de campo médio.




Figura 2

Quando a quarentena é aplicada, o pico é adiado e achatado, e o número total de recuperados diminui em cerca de 30% (Figura 2). A barreira central divide a epidemia em dois focos isolados, retardando significativamente a propagação entre as metades da população.

Esses resultados exemplificam o poder do autômato celular para avaliar intervençõeses pacialmente explícitas, uma tarefa difícil com equações diferenciais ordinárias.

4. Discursão

O código apresentado preenche uma lacuna didática e de pesquisa: embora existam pacotes sofisticados para IBM como GAMA e NetLogo, uma implementação enxuta em Python permite maior transparência e customização por parte do usuário, o que permite que estudantes possam inspecionar cada linha e modificar regras, facilitando o aprendizado de conceitos de simulação estocástica e emergência, permite pesquisa exploratória já que o código serve como ponto de partida para testar hipóteses sobre mobilidade, heterogeneidade de contatos e eficácia de medidas não-farmacológicas, além de facilitar a reprodutibilidade, por ser auto-contido e dependente apenas de bibliotecas padrão, os experimentos descritos podem ser replicados com um clique.

É preciso ressaltar algumas limitações como a ausência de demografia realista e a simplificação do movimento como difusão simples, mas que extensões futuras podem incorporar dados censitários e redes de transporte o que poderia reduzir algumas limitações.

5. Conclusão

Descrevemos um autômato celular estocástico para o modelo SEIR com heterogeneidade espacial, implementado em Python. O código, disponível

publicamente, é uma ferramenta versátil para explorar a dinâmica espacial de epidemias. Demonstramos seu uso em cenários hipotéticos, revelando como intervenções localizadas alteram o curso da doença. Torcemos para que esse trabalho incentive a adoção de abordagens baseadas em indivíduos no ensino e na pesquisa em epidemiologia computacional.

Referências

- 1 Kermack, W. O., & McKendrick, A. G. (1927). A contribution to the mathematical theory of epidemics. *Proc. R. Soc. Lond. A*, 115(772), 700-721.
- 2 Riley, S. (2007). Large-scale spatial-transmission models of infectious disease. *Science*, 316(5829), 1298-1301.
- 3 Kraemer, M. U., et al. (2020). The effect of human mobility and control measures on the COVID-19 epidemic in China. *Science*, 368(6490), 493-497.
- 4 White, S. H., del Rey, A. M., & Sánchez, G. R. (2007). Modeling epidemics using cellular automata. *Applied Mathematics and Computation*, 186(1), 193-202.
- 5 Fuentes, M. A., & Kuperman, M. N. (1999). Cellular automata and epidemiological models with spatial dependence. *Physica A*, 267(3-4), 471-486.
- 6 Santos, L. B. L., et al. (2009). Modelos de autômatos celulares para propagação de doenças. *TEMA*, 10(2), 245-254.
- 7 Keeling, M. J., & Rohani, P. (2008). *Modeling Infectious Diseases in Humans and Animals*. Princeton University Press.
- 8 Keeling, M. J., & Rohani, P. (2008). Capítulo 6: Spatial heterogeneity. In: *Ibid.*, pp. 195-248.